

Pequenos negócios perdem clientes por **demora na resposta** — e levam bloqueio quando tentam disparar mensagens.

60-80%

CLIENTES QUE SOMEM

Quando a primeira resposta demora mais de 5 minutos. O cliente já fechou com o concorrente.

7 dias

ATÉ O WHATSAPP BLOQUEAR

Quem envia muita mensagem igual, sem opção de "sair", em qualquer horário — leva ban da Meta em uma semana.

R\$ 0

VERBA PARA VENDEDOR HUMANO

PME (pequena ou média empresa) não tem dinheiro pra time comercial 24/7. Precisa atender, qualificar e encaminhar com IA.



CASO REAL (EXEMPLO)

Uma corretora de imóveis recebe 50 contatos por dia vindos de anúncios no Facebook/Instagram. 80% chegam fora do horário comercial. Quando o corretor responde de manhã, a pessoa já fechou com outra imobiliária.

Um sistema que **atende**, **qualifica** e **dispara** com regras claras.

01

INBOUND · CLIENTES QUE CHEGAM

Atendimento automático

O robô faz **4 perguntas-chave** para entender se a pessoa é um cliente real: o que quer, onde, quanto pode investir e qual a pressa. Esse método é chamado **BANT** (sigla em inglês para Orçamento, Autoridade, Necessidade e Prazo). Depois passa pro humano.

02

OUTBOUND · MENSAGENS ATIVAS

Disparo com 14 travas

Para reativar clientes antigos sem ser bloqueado: volume baixo, intervalo aleatório, horário comercial, mensagens variadas, validação do número antes do envio.

03

SISTEMA REUTILIZÁVEL

Adapta para qualquer ramo

Mesma engenharia serve para imobiliária, dentista, barbearia ou advogado. Só muda o arquivo de configuração — toda a estrutura é reaproveitada.

CAMADA 01

Perceptiva

Recebe a mensagem

Webhook
EvoLution API
JSON entrando

CAMADA 02

Cognitiva

Pensa e interpreta

AI Agent
GPT-4o-mini
Memória curta

CAMADA 03

Decisória

Decide o que fazer

IF (regras)
Limpeza de saída
Caminho "Sair"

CAMADA 04

Executiva

Age no mundo

Envia mensagem
Atualiza planilha
Registra log

As 4 perguntas BANT (qualificação)

✓ **Intenção:** comprar / vender / alugar

Identifica o tipo de necessidade

✓ **Região:** bairro de interesse

Para roteamento ao corretor da área

✓ **Orçamento:** faixa de valor

Confirma capacidade de compra

✓ **Urgência:** 30 dias / 90 dias / explorando

Define prioridade de atendimento

✓ **Limpeza automática:** remove etiquetas técnicas

Cliente nunca vê códigos de máquina



SP Imóveis · Atendimento

online · respondendo em 3s

oi

Oi! Aqui e o atendimento da SP Imoveis. Pra te ajudar melhor, voce esta querendo comprar, vender ou alugar?

comprar

Otimo! Em qual bairro da Zona Norte tem interesse?

Santana

Excelente regioao. Qual sua faixa de orcamento?

500 mil

Anotado. E a urgencia: imediato 30d, curto 60d

Volume baixo, parecer humano, respeitar a LGPD (Lei Geral de Proteção de Dados).

#	TRAVA	COMO FUNCIONA (LINGUAGEM CLARA)
01	Volume baixo	Envia 1 mensagem por vez (configuração <code>batchSize=1</code>)
02	Apenas em horário comercial	Só envia entre 9h-12h e 13h-18h (horário de Brasília)
03	Intervalo aleatório	Espera entre 15 e 90 segundos com 1 casa decimal — não fica "redondo" como bot
04	3 textos diferentes	Sorteia entre 220, 240 ou 320 caracteres (formal, médio ou conversacional)
05	Personalização	Substitui <code>{{nome}}</code> e <code>{{empresa}}</code> pelos dados reais do contato
06	Bloqueio de palavras de spam	Rejeita textos com "desconto", "urgente", "grátis", "imperdível"
07	Sem links na 1ª mensagem	Regra textual (regex) bloqueia <code>http(s)://</code> e <code>www.</code>
08	Validação de número	Verifica se o telefone tem WhatsApp antes de enviar
09	Mostra "digitando..."	O destinatário vê o status "digitando" por 3 a 7 segundos antes da mensagem chegar
10	Tamanho variado	Mensagens entre 80 e 600 caracteres (não dá pra ser todas iguais)
11	Opção de sair	Se a pessoa responder "SAIR", marca o status sem chamar a IA — caminho direto no código
12	Consentimento prévio (LGPD)	Só dispara se a coluna <code>consentimento=TRUE</code> estiver marcada na planilha
13	Auditoria por linha	Registra na planilha: quantas tentativas, qual mensagem, qual horário
14	Anti-reenvio	Só envia para quem está com status pendente — nunca duplica



TERMO APLICADO · KILL-SWITCH NORMALIZADO

A trava 06 (palavras de spam) usa o que chamamos de **kill-switch normalizado**: antes de comparar, o texto passa por `String.normalize('NFD')` que remove acentos via Unicode. Isso significa que o filtro detecta "promoção" e "promocao" igual — acentuação criativa não burla.

- COMO FUNCIONA EM UMA IMAGEM · SEM JARGÃO

Dois fluxos, uma única engine.

Mesma engenharia atende duas situações opostas: cliente que chega (Inbound) e cliente que precisamos buscar (Outbound). A peça que costura tudo é o que a literatura chama de **orquestrador** — uma camada que coordena APIs sem precisar escrever código.

INBOUND

Cliente chega

Resposta em 3 segundos



Cliente manda mensagem



Bot responde 3s



4 perguntas BANT



Dados estruturados



Atendente humano

OUTBOUND

Empresa busca

14 travas anti-bloqueio



Lista de leads



14 travas anti-ban



Espera aleatória



Mensagem enviada



Status atualizado



TERMO APLICADO · WEBHOOK

O ponto de entrada do Inbound (📱 → 🤖) é um **webhook**: uma URL que fica esperando o WhatsApp avisar "chegou mensagem nova". Em vez de o sistema ficar perguntando toda hora, ele é notificado no instante zero. É o que viabiliza os 3 segundos de resposta.

Mega-prompt: a instrução do robô em 5 partes.

Em vez de uma instrução solta, organizamos a "personalidade" do bot em 5 blocos com etiquetas estruturadas (XML — formato que a IA reconhece muito bem porque foi treinada em bilhões de páginas web).

```
// Instrução base do bot – versão 5

<contexto>
  Voce e um atendente digital de uma
  imobiliaria na Zona Norte de SP.
  Atende pelo WhatsApp.
</contexto>

<instrucao>
  Faca UMA pergunta por vez. Conduza
  ate coletar: intencao, regioao,
  orcamento, urgencia. Ao concluir,
  emita etiqueta de dados.
</instrucao>

<formato_obrigatorio>
  Sem acento, sem cedilha, sem
  formatacao. Final:
  TRIAGEM_COMPLETA{...JSON...}
</formato_obrigatorio>

<exemplos>
  Conversa-exemplo de 4 turnos.
</exemplos>

<constraints>
  Em duvida sobre preco:
  "Apenas um corretor pode confirmar"
</constraints>
```

Por que funciona

- ✓ **Etiquetas separam cada parte**
Sem confusão entre instrução e exemplo
- ✓ **IA aprendeu a ler XML**
Foi treinada em bilhões de páginas com tags
- ✓ **Regras positivas**
Diz "o que fazer" — não "o que evitar"
- ✓ **Few-shot (exemplos prontos)**
O robô copia o estilo da conversa-modelo
- ✓ **Etiqueta de dados no final**
Ao concluir, gera código que máquina lê

"Os 5 elementos em sinergia produzem comportamento previsível mesmo em modelos pequenos." — Carraro, 2023

A IA escreve **duas coisas ao mesmo tempo** — e o código separa.

A mensagem amigável que chega no WhatsApp, e os dados estruturados que vão pro CRM. Em vez de pedir pra IA decidir entre "escrever bonito" ou "estruturar dado", pedimos as duas coisas **juntas**. Um pedaço do código separa antes de enviar.

Saída crua da IA (1 mensagem só)

```
// O que a IA produz internamente
Perfeito! Vou alocar um corretor
especializado pra você, em
instantes ele entra em contato.

TRIAGEM_COMPLETA{
  "intencao": "comprar",
  "regiao": "Santana",
  "faixa": "500k",
  "urgencia": "30d"
}
```

Isso é tudo que a IA gerou. Agora vem a mágica: o código **parte ao meio** antes do envio.

Após o "Sanitize" (separa em 2)

VAI PRO WHATSAPP

Perfeito! Vou alocar um corretor especializado pra você, em instantes ele entra em contato.

VAI PRO CRM (ESTRUTURADO)

```
{ "intencao": "comprar",
  "regiao": "Santana",
  "faixa": "500k",
  "urgencia": "30d" }
```




TERMO APLICADO • SEPARATION OF CONCERNS

Mello (2024) chama isso de **separation of concerns**: separar o que a IA *fala com humano* do que ela *fala com máquina*. Sem essa camada, o cliente receberia o JSON na conversa — quebra a experiência. Com ela, o lead vai pro CRM no mesmo segundo da resposta.

Por que GPT-4o-mini em maio/2026?

Equilíbrio entre custo, velocidade e qualidade. Para um chatbot de WhatsApp em português com perguntas simples, é o melhor custo-benefício do mercado.



MODELO	CUSTO por 1 milhão de palavras	VELOCIDADE	ACERTO teste MMLU
GPT-4o-mini ESCOLHIDO	\$0,15	~400ms	82%
Claude Haiku 3.5	\$1,00	~800ms	76%
GPT-4o	\$2,50	~600ms	88%
GPT-3.5-turbo	\$0,50	~350ms	70%



ARGUMENTO AMBIENTAL · TERMO APLICADO · MMLU

Modelo mais barato = menos processamento computacional = menos consumo de energia por resposta. Mesmo com 82% no **MMLU** (benchmark padrão da indústria que mede acurácia em 57 tarefas de raciocínio), GPT-4o-mini reduz a pegada de carbono em ~10x comparado ao GPT-4o (Mello, 2024).

Substitui um SDR por 5% do custo.

SDR (Sales Development Representative) é o profissional que faz triagem de leads. Custa entre R\$ 2.500 e R\$ 4.000 por mês. Nosso sistema entrega o mesmo trabalho — operando 24/7, com qualidade auditável — por R\$ 155.

Custo mensal · 1.000 conversas

ITEM	CUSTO (USD)	R\$ APROX.
n8n Cloud (orquestrador)	\$24,00	R\$ 120
Railway (Evolution API)	\$5,00	R\$ 25
OpenAI · GPT-4o-mini	\$2,00	R\$ 10
Google Sheets	\$0,00	R\$ 0
TOTAL infraestrutura	\$31,00	R\$ 155

Custo por conversa = R\$ 0,15. Já inclui resposta da IA, orquestração e envio pelo gateway. Escala linear até ~10k conversas/mês.

Comparativo direto

SDR JÚNIOR

R\$ 3.000 / mês

Atende em horário comercial. Demora minutos para responder. Não escala.

MANYCHAT / WATI (CONCORRENTES)

US\$ 15-100 / mês

Plataforma fechada com fluxos pré-prontos (botões, listas). Não usa LLM nativo. Menos flexível.

PROMPTZEIROS

R\$ 155 / mês

Atende 24/7 em 3s. Conversa natural com LLM. Engine reutilizável em qualquer ramo.



TERMO APLICADO · ROI (RETURN ON INVESTMENT)

ROI de aproximadamente 20× contra um SDR humano. Em outras palavras: a empresa recupera o investimento em menos de 1 semana de uso. Para PME que não tem verba pra time comercial, isso muda o jogo.

Em 2 minutos, o bot vira qualquer ramo.

A "máquina" do sistema (recebe → pensa → decide → envia) **nunca muda**. Só muda a "personalidade" do robô — o arquivo de configuração que descreve o ramo de atuação.

1 A banca sugere o ramo

"Barbearia em Pinheiros", "dentista do Tatuapé", "advogado tributarista". Qualquer pequeno negócio.

2 O modelo gera a nova personalidade

O ChatGPT ou Claude recebe um "modelo de instrução" pré-pronto e gera o novo system prompt aplicando os 5 elementos do Carraro — em 5 a 10 segundos.

3 Cola na ferramenta e publica

Mesma estrutura, nova instrução. O cliente manda "oi" e o bot responde já como o novo ramo.



TERMO APLICADO · TEMPLATE PARAMETRIZADO DINÂMICO

Mello (2024) chama isso de **template parametrizado dinâmico**: arquitetura rígida com prompt flexível. A estrutura é estável — mesmos nodes, mesmos endpoints, mesmas validações. O conteúdo é variável — só o JSON do system prompt muda. É o que separa um chatbot de uma plataforma escalável.

Quanto mais autônomo o robô, maior nossa responsabilidade.

Garantias técnicas

- ✓ **Opção SAIR sem IA**
Se o cliente digita "SAIR", o sistema vai direto para o caminho de cancelamento — não passa pelo robô
- ✓ **Consentimento na planilha**
Coluna `consentimento=TRUE` obrigatória — sem ela, lead nem entra no envio
- ✓ **Bloqueio fora do horário**
Mensagens noturnas e fim de semana não saem
- ✓ **Tudo registrado**
Cada envio guarda data, modelo de mensagem e identificador único
- ✓ **Anti-invenção**
Se o cliente pergunta preço, o robô responde "só um corretor pode confirmar" — nunca chuta

Princípios aplicados

Interpretabilidade. Cada decisão importante é tomada por código com regras claras, não pela IA — princípio de Murta (2023).

Transparência. Toda mensagem de disparo identifica quem está falando e oferece opção de sair logo na primeira interação.

Conformidade Meta. Seguimos a política do WhatsApp 2026: volume baixo, conteúdo personalizado, sem links na primeira mensagem.



TERMO APLICADO · OPT-OUT DETERMINÍSTICO

O caminho do "SAIR" é o que chamamos de **opt-out determinístico**: passa por uma regra de código (IF), não pela IA. LGPD não pode falhar por alucinação do modelo — a saída da lista precisa ser 100% garantida, sempre. Só o que é determinístico oferece essa garantia.

Maturidade desta primeira versão é **honestas** — e o caminho está mapeado.

Limites que assumimos: usamos o Evolution (versão não-oficial do WhatsApp, há risco de bloqueio em volume alto) · a memória do bot mora em arquivo temporário (não vira histórico permanente) · custo cresce conforme volume.

M1 · ENTREGUE AGORA

Atendimento + disparo

Triagem das 4 perguntas BANT no atendimento · disparo manual com 14 travas · opção SAIR garantida · sistema reutilizável para qualquer ramo.

M2 · 2 SEMANAS

Memória + integrações

Memória permanente em banco de dados · IA chamando ferramentas externas (consultar imóveis, agendar visita) · painel com métricas em tempo real.

M3 · 1 MÊS

Áudio + foto + CRM

Cliente manda áudio? IA transcreve (Whisper). Manda foto do imóvel? IA descreve (Vision). Conecta no sistema de gestão de clientes (HubSpot/RD Station).



PARA USO EM PRODUÇÃO

Acima de 50 mensagens por dia, recomendamos migrar para um fornecedor oficial Meta (YCloud, Twilio, 360dialog). O Evolution serve perfeitamente para o que entregamos: um MVP educacional gratuito.

 Mapeamento da rúbrica

5 elementos do prompt	system-prompt-v7.md
Few-shot + XML tags	Em produção
Arquitetura 4 camadas	DIAGRAMA.md
Justificativa modelo IA	Memorial §6
Memória conversa	Buffer 20 turnos
Limitações + ética	Memorial §8 e §10
Demo ao vivo	WhatsApp + n8n

 Por que é MVP

- Foco didático** — prioriza demonstrar conceitos da disciplina, não escala
- Stack acessível** — n8n + Sheets + Evolution = R\$ 155/mês, sem servidor próprio
- Marker textual + regex** — em vez de Function Calling, simples e debugável
- Buffer Window** — memória curta, não persiste entre reinícios
- Evolution API** — gateway open-source, ideal pra MVP, risco em volume alto

 Upgrade para cliente real

- BSP oficial Meta** — YCloud, Twilio ou 360dialog (zero risco de ban)
- Function Calling** — JSON estruturado nativo da OpenAI
- Memória em Postgres** — histórico permanente + auditoria
- CRM nativo** — HubSpot, Pipedrive, RD Station